

МиоБанд

Автори: Никола Д. Лилов, Виктор М. Атанасов, Станислав К. Янков, Ян Р. Генов

Заглавие: МиоБанд: Разпознаване на жестове на ръката чрез повърхностна електромиография

Резюме: МиоБанд е проект в областта на биомедицинското инженерство, електрониката и компютърните науки, насочен към разпознаване на жестове на ръката чрез повърхностна електромиография (sEMG). Разработваната гривна регистрира биоелектрическата активност на мускулите чрез повърхностни електроди, а получените сигнали се обработват и класифицират, за да бъдат преобразувани в компютърни команди. Основната цел на проекта е да се изследват възможностите на sEMG за надеждно разпознаване на различни жестове и да се разработи практична, компактна и достъпна система за взаимодействие човек–компютър. Оригиналният принос на разработката е в цялостното проектиране и интегриране на хардуерната и софтуерната част на системата, включително регистриране и обработка на сигналите и алгоритъм за класификация на жестовете. Всеки елемент от проекта разучаваме от нулата, което ни позволява да анализираме отделните компоненти на системата и взаимодействието между тях, както и да направим стойностни изводи за тяхната ефективност. Получените резултати показват принципната постижимост на подхода и очертават практични възможности за приложение.

Title: MyoBand: Hand-Gesture Recognition via Surface Electromyography

Abstract: MyoBand is a project in the fields of biomedical engineering, electronics, and computer science, focused on hand-gesture recognition using surface electromyography (sEMG). The developed wristband records the bioelectrical activity of muscles through surface electrodes, while the acquired signals are processed and classified to be converted into computer commands. The main goal of the project is to investigate the capabilities of sEMG for reliable recognition of different gestures and to develop a practical, compact, and affordable human–computer interaction system. The original contributions of the work lie in the development of the overall design and integration of the hardware and software components of the system, including signal acquisition and processing and a gesture-classification algorithm. Every element of the project is researched from scratch, allowing us to analyze the individual components of the system and the interactions between them, as well as to draw meaningful conclusions about their effectiveness. The obtained results demonstrate the feasibility of the approach and outline practical possibilities for its application.

GitHub: github.com/MyoBand-Group/MyoBand

Дата: 04 октомври, 2026 г.

Съдържание:

1. Увод: цели и мотивации:	3
2. Pipeline и архитектура на прототипа:	4
2.1. Физически дизайн:	4
2.2. Основни хардуерни компоненти:	5
2.3. Обработка на данните чрез Изкуствен интелект:	5
2.4. Комуникация и управление:	6
3. Хардуер:	6
3.1. Аналогова предна част и Транзистори:	6
3.1.1. Принцип на действие на MOSFET:	6
3.1.2. Режими на работа и математически модел:	7
3.2. Усилватели:	7
3.2.1. Операционни усилватели (Op-Amp):	8
3.2.2. Инструментални усилватели (In-Amp):	9
3.3. Current Mirror:	9
3.4. Current booster:	10
4. Pre-Processing:	11
5. Изкуствен интелект (Невронни мрежи):	12
5.1. Структура на мрежата и Forward Propagation:	12
5.2. Activation Functions:	13
5.3. Backward Propagation:	13
5.4. Gradient Descent и Learning Rate:	13
5.5. Loss function и SoftMax:	14
5.6. Parallelization & CUDA optimization:	15
5.7. Матрично умножение:	16
6. Post-Processing: Интерпретиране на резултатите:	18
7. Апликации:	18
8. Заключение:	19
8.1. Приноси:	20
8.2. Бъдещо развитие:	21
9. Източници:	22

1. Увод: цели и мотивации

Развитието на съвременните технологии създава все повече възможности за изграждане на естествени, интуитивни и достъпни начини за взаимодействие между човека и компютъра. Традиционните средства за управление, като клавиатурата и мишката, са ефективни в широк кръг от приложения, но не винаги осигуряват най-удобния начин за комуникация с устройствата. Това поражда интерес към разработването на алтернативни интерфейси, които използват движенията и физиологичните сигнали на човешкото тяло като средство за управление.

Един от подходите за реализиране на подобни интерфейси е повърхностната електромиография (surface electromyography, sEMG) – метод за регистриране на биоелектрическата активност на мускулите чрез електроди, поставени върху повърхността на кожата. Получените сигнали съдържат информация за мускулната активност и могат да бъдат анализирани с цел разпознаване на определени движения и жестове. Тяхното използване обаче поставя редица технически предизвикателства, свързани с ниската амплитуда на сигналите, наличието на електрически шум, различията между отделните измервания и необходимостта от надеждна класификация на регистрираните данни.

Проектът „МиоБанд“ е насочен към изследването на тези предизвикателства чрез разработването на компактна носима система за разпознаване на жестове на ръката и преобразуването им в команди към компютър. Разработката обединява знания и методи от биомедицинското инженерство, аналоговата и цифровата електроника, вградените системи и машинното обучение. Чрез интегрирането на тези области се цели изграждането на цялостно решение, при което регистрирането на мускулната активност, обработката на сигналите, разпознаването на жестовете и предаването на командите се осъществяват като взаимосвързани етапи на една система.

Основната цел на проекта е да се проектира, изгради и изследва функциониращ прототип на носима електронна гривна, която използва повърхностни електромиографски сигнали за разпознаване на жестове на ръката и управление на компютър чрез безжична комуникация.

За постигането на тази цел са формулирани следните основни задачи:

- a. Проектиране и изграждане на хардуерната система – разработване на електронна платка и компактна физическа конструкция, които интегрират EMG сензорите, усилвателните схеми и микроконтролера.
- b. Разработване на изкуствен интелект за разпознаване на жестове – създаване и обучение на изкуствена невронна мрежа, която анализира постъпващите данни и определя вероятността те да съответстват на предварително зададени класове движения.

Съществена особеност на проекта е стремежът към самостоятелно разработване на отделните хардуерни и софтуерни компоненти и към изследване на взаимодействието между тях. По този начин работата не се ограничава до сглобяване на готови модули, а включва проектиране на електронни схеми, разработване на програмна логика и анализ на различни методи за обработка на информацията. Оригиналният принос на разработката се състои в интегрирането на тези компоненти в обща система за разпознаване на жестове, както и в разработването и сравнителното изследване на собствени реализации на алгоритми за обучение на невронни мрежи с различни нива на паралелизация.

Настоящата разработка е организирана в няколко основни части, които разглеждат последователно физическата реализация на гривната, електронните принципи, обработката на данните и изчислителните алгоритми, използвани в проекта.


В глава 2 е представена общата архитектура на разработвания прототип „МиоБанд“, включително физическият дизайн на гривната, основните хардуерни компоненти, обработката на данните и комуникацията с компютър. В глава 3 са разгледани хардуерните принципи, използвани при изграждането на аналоговата част на системата, включително MOSFET транзистори, усилватели, current mirror и current booster. Глава 4 представя подходите за предварителна обработка на EMG сигналите и извличане на допълнителни характеристики. В глава 5 е описан AI моделът за разпознаване на жестове чрез изкуствена невронна мрежа, както и основните етапи на обучението и различните реализации за ускоряване на изчисленията чрез SIMD, SIMT и матрични операции с cuBLAS. В глава 6 е разгледано последващото обработване на резултатите от класификацията и превръщането им в конкретни команди към компютъра. Глава 7 представя възможните приложения на разработената система. В глава 8 са обобщени резултатите от проекта, формулирани са основните приноси на разработката и са очертани възможностите за нейното бъдещо развитие. В глава 9 са представени използваните източници.

2. Pipeline и архитектура на прототипа

2.1. Физически дизайн

Основните компоненти на гривната са EMG сензорите, свързани със съответните усилватели, които ни дават аналогов сигнал, който преминава в ESP32-S3 (микроконтролер) за последваща обработка, като успоредно с това използваме данните от жироסקоп и акселерометър, за да прецизираме резултатите. Дадените компоненти като усилвател и ESP се намират на PCB, специално направено да минимизира обема, като междувременно се намира на върха на ръката, като основите на гривната са 3D принтирани, за да е солидно самото тяло. По цялата дължина на гривната са разположени EMG сензори, с които се получава основната част от данните (позиционирането на електродите е избрано с оглед на разположението на целевите мускули и качеството на регистрирания сигнал). Всички тези компоненти са закрепени върху гумена основа, за да се гарантира надежден контакт и стабилност.

2.2. Основни хардуерни компоненти




Основната платка е проектирана специално за проекта и разполага с обособени площадки за директно запояване на микроконтролера за директна интеграция към проекта и ни дава възможност да оптимизираме компонентите на платката за максимална точност на данните, отделните краища на сензорите биват допрени към ръката, които я държат на място. На платката, освен микроконтролера, обработващ данните, имаме и поставен MPU-6050 чип, съдържащ акселерометър и жирокоп, които ни дават възможност за разграничаване на допълнителни жестове. Всичко това бива захранвано от 3.7 V 500mAh Li-Po батерия.

2.3. Обработка на данните чрез Изкуствен интелект

Данните, които идват от усилвателите, се препращат към микроконтролера, за да бъдат превърнати от аналогов към бинарен сигнал. След това данните от различните сензори се комбинират и, локално в микроконтролера, биват интерпретирани от предварително трениран AI модел, който в зависимост от формата на отделните графики. AI моделът предава процентния шанс различно движение да е било извършено. Имаме предварително избрана комбинация от движения. Предсказаният от AI-а резултат бива запаметен на микроконтролера и после изпратен на компютъра. Важно е да се добави, че данните от акселерометъра и жирокопа могат да се използват за потвърждаване на предсказаните резултати или в определени случаи (в зависимост от желания ефект) директен резултат (например, местене на мишката).

Изобразен е общият вид на данните: отгоре е формата на едно стискане на ръката + базов шум/пулс; отдолу са 4 последователни стискания.



2.4. Комуникация и управление

Крайният резултат, който е бил в паметта на микроконтролера, се изпраща чрез Bluetooth на основния компютър, към който е свързана гривната. Това дава възможността, спрямо движението, директно да се изпрати определена команда.

3. Хардуер

3.1. Аналогова предна част и Транзистори

Транзисторите са активни електронни компоненти, които функционират като управляеми ключове или усилватели. Всеки транзистор има три основни извода. При прилагане на управляващо напрежение (или ток) към третия извод (гейт/база), компонентът контролира протичането на ток между другите два извода (сорс-дрейн или емитер-колектор). В дигиталния контекст транзисторът работи като електронен ключ.

Съществуват два основни типа често използвани транзистори:


- BJT – Bipolar Junction Transistor
- MOSFET – Metal-Oxide-Semiconductor Field-Effect Transistor

При модерната микроелектроника предимно се използват MOSFET-ите.

3.1.1. Принцип на действие на MOSFET

MOSFET транзисторите се различават фундаментално от BJT по това, че техният управляващ извод (гейт) е електрически изолиран от проводящия канал чрез тънък слой диелектрик (силициев диоксид). Тази структура действа като вграден микроскопичен кондензатор между гейта и сорса.

Този изолиращ слой осигурява изключително висок входен импеданс (типично между $10^9 \Omega$ и $10^{12} \Omega$). В идеалния случай входният импеданс се стреми към безкрайност. Това е важно за нашия проект, тъй като електромиографските (EMG) сигнали, идващи от човешкото тяло, са с изключително ниска мощност. Ако входният импеданс на усилвателя е нисък, сигналът от тялото ще затихне и ще се изгуби. Благодарение на високия импеданс на MOSFET, през гейта практически не протича ток от сензорите към усилвателната част.



Когато се приложи напрежение към гейта, създаденото електрическо поле прониква през диелектрика и въздейства върху полупроводниковата подложка. Това поле индуцира перпендикулярно напрежение, което променя концентрацията на токоносители под гейта:

- При n-канален MOSFET (NMOS), положителното напрежение на гейта привлича свободни електрони и отблъсква електронните дупки, превръщайки p-зоната в n-тип инверсионен канал. Токът се пренася от отрицателни токови носители (електрони).

- б. При р-канален MOSFET (PMOS) процесът е огледален – формира се канал от положителни токови носители (дупки).

3.1.2. Режими на работа и математически модел

В триоден (линеен) режим, когато транзисторът е отворен и напрежението между гейта и сорса е над праговото $V_{GS} > V_{th}$, но напрежението сорс-дрейн е ниско $V_{GS} - V_{th} > V_{DS}$, токът на дрейна I_D се описва със следната формула:

$$I_D = \mu_n C_{ox} \frac{W}{L} \left[(V_{GS} - V_{th}) * V_{DS} - \frac{V_{DS}^2}{2} \right], \text{ където:}$$

I_D – Ток на дрейна (Drain current), протичащ през транзистора.

μ_n – Подвижност на токовите носители (електроните) в канала.

C_{ox} – Специфичен капацитет на диелектричния оксиден слой на единица площ.

W – Широчина на канала (Channel width) – геометричен параметър на транзистора.

L – Дължина на канала (Channel length) – разстоянието между сорса и дрейна.

V_{GS} – Напрежение между гейта и сорса (Gate-to-Source voltage) – управляващото напрежение.

V_{th} – Прагово напрежение (Threshold voltage) – минималното напрежение, необходимо за отваряне на канала.

V_{DS} – Напрежение между дрейна и сорса (Drain-to-Source voltage).

Когато напрежението V_{DS} нарасне до такава степен, че $V_{GS} - V_{th} \leq V_{DS}$, в края на канала до дрейна се наблюдава ефект на стесняване на канала (Pinch-off). Транзисторът навлиза в режим на насищане (Saturation region). В този режим токът спира да зависи от V_{DS} и става постоянен (стабилизиран), а формулата се опростява до:

$$I_D = \frac{1}{2} \mu_n C_{ox} \frac{W}{L} (V_{GS} - V_{th})^2$$

Тъй като в режим на насищане токът I_D е независим от V_{DS} , транзисторът се държи като идеален източник на ток, управляван от напрежение. Това свойство е изключително ценно за постигане на високо усилване.

3.2. Усилватели

Стандартният усилвател се състои от захранващ източник V_{DD} , товарен резистор R_D , MOSFET транзистор и резистор в сорса R_S , свързан към земя. Входният сигнал се подава към гейта V_G .

От уравненията за режима на насищане и закона на Ом можем да съставим следната система от уравнения, описваща правотоковата (DC) работната точка на усилвателя:


$$\begin{cases} I_D = k(V_G - V_S - V_{th})^2 \\ I_D = \frac{V_{DD} - V_D}{R_D} \\ I_D = \frac{V_S}{R_S} \end{cases}$$

(Параметърът $k = \frac{1}{2} \mu_n C_{ox} \frac{W}{L}$ обединява конструктивните константи на транзистора).

Какво НЕ знаем директно и трябва да намерим от тези формули при проектиране:

При изчисляване на схемата неизвестните променливи обикновено са работният ток на дрейна I_D , напрежението на сorsa V_S и изходното напрежение на дрейна V_D . Чрез решаване на системата определяме точните стойности на резисторите R_D и R_S , за да настроим усилвателя в линейната му зона.

Изходното напрежение се взема от дрейна V_D , а коефициентът на усилване (амплификация A_D) зависи от стойностите на резисторите и стръмността на транзистора ($g_m = \frac{\partial I_D}{\partial V_{GS}}$): $A_D \approx -g_m \cdot R_D$. Проблемът на този тип базови усилватели е, че параметърът k (и съответно g_m) е изключително нестабилен при температурни промени. Това прави коефициента на усилване непредвидим. За преодоляване на този недостатък е създаден операционният усилвател (Op-Amp).



3.2.1. Операционни усилватели (Op-Amp)


Операционният усилвател разполага с два входа (инвертиращ и неинвертиращ) и един изход. На базово ниво неговото стъпало представлява диференциална двойка от два идентични транзистора с общ източник на постоянен ток към земя (наречен "токово огледало", осигуряваща стабилен ток).

Този усилвател изважда двете входни напрежения ($V_+ - V_-$) и амплифицира само разликата между тях. Формулата за изходното напрежение при отворена обратна връзка е:

$$V_{out} = A_{OL} \cdot (V_+ - V_-)$$

Където A_{OL} е коефициентът на усилване по напрежение без обратна връзка (обикновено над 100 000).

Понеже схема изважда двата сигнала, всеки сигнал, който присъства едновременно и на двата входа (напр. индуциран шум от околната среда), се



анулира. Този ефект се нарича Потискане на синфазния сигнал (CMRR - Common-Mode Rejection Ratio). Това прави операционните усилватели перфектни за филтриране на външния шум, уловен от човешкото тяло, и за изолиране на фините, уникални биоелектрични импулси на отделните мускули.

Обаче, за да работи диференциалният усилвател правилно и с точен коефициент на усиление, външните резистори в схемата му трябва да бъдат перфектно съгласувани. Дори минимално отклонение в толеранса на резисторите (поради производствен дефект или температура) драстично влошава CMRR и нарушава баланса на компонента.

3.2.2. Инструментални усилватели (In-Amp)

За решаване на този проблем в медицинската апаратура се използва Инструментален усилвател (Instrumentation Amplifier). Той интегрира в себе си три операционни усилвателя:

Два входни буферни усилвателя, които осигуряват екстремно висок входен импеданс и първоначално усиление на сигнала.


Един диференциален усилвател, който извършва прецизното изваждане на сигналите и премахва шума.

Вътрешните резистори на Инструменталния усилвател са лазерно калибрирани още в завода с точност до 1/100 000 (0.001%). Коефициентът на усиление се настройва изключително лесно и прецизно чрез промяната на само един единствен външен резистор (R_G).

В нашия проект за EMG гривна използваме именно инструментални усилватели, тъй като човешкото тяло действа като антена, която постоянно улавя 50 Hz / 60 Hz смущения от електрическата мрежа в стените. Тези смущения са хиляди пъти по-силни от микроволтажните импулси на мускулите ни. Инструменталният усилвател успешно потиска този синфазен мрежов шум и извлича чистия мускулен сигнал.

3.3. Current Mirror


За осигуряване на необходимия режим на работа на диференциалния усилвател се използва токово огледало. Неговата функция е да генерира стабилен референтен ток и прецизно да го възпроизведе към товара (в случая – сорсовете на транзисторите във входното стъпало). В основната си конфигурация токовото огледало се реализира чрез два съгласувани MOSFET транзистора, интегрирани върху общ силициев кристал, за да се гарантират идентични електрически и термични характеристики. Първият (референтен) транзистор е свързан в диодно включване (гейтът и дрейнтът са свързани накъсо), като токът през него се



задава чрез външен елемент и захранващото напрежение. Тъй като гейтовете на двата транзистора са свързани паралелно, техните напрежения гейт-сорс (V_{GS}) са равни. Теоретично това условие осигурява протичането на идентичен дренажен ток и през втория (изходен) транзистор.


В реални условия обаче, двутранзисторната схема проявява отклонения и изходният ток не съвпада напълно с референтния. Основната причина за тази асиметрия при полевите транзистори е ефекта на Модулация на дължината на канала. Този ефект се проявява вследствие на разликата в напреженията дрейн-сорс (V_{DS}) на двата транзистора. При референтния транзистор това напрежение е фиксирано от диодното му включване, докато при изходния то варира и често е по-голямо поради връзката му с товара на схемата. Тази разлика в потенциалите води до нежелано нарастване на изходния ток. Следователно, постигането на висока точност на огледалото изисква изравняване на напреженията върху дрейновете на двата транзистора.

За компенсиране на модулацията на дължината на канала топологията се модифицира чрез добавяне на допълнителни транзистори. Висока прецизност се постига чрез четири транзистора, при които към двата клона се добавят допълнителни транзистори. Тяхната функция е да компенсират потенциалните разлики, осигурявайки пълно равенство между напреженията V_{DS} на основната огледална двойка. Тази усъвършенствана схема ефективно неутрализира ефекта от модулацията на дължината на канала, увеличава значително изходното съпротивление на огледалото и гарантира изключително точно копиране на референтния ток.





3.4. Current booster

Последното стъпало на един операционен усилвател е токовият усилвател. След като сигналят премине през диференциалния усилвател, синфазният шум е потиснат, а амплитудата на напрежението е значително усилена. Въпреки това остава един проблем: повечето външни товари изискват значително по-голям ток за управление – обикновено в порядъка на милиампери (mA). Тъй като токът от предходните стъпала е много слаб (в порядъка на наноампери), е необходимо да се използва схема, която да осигури нужното усиление по ток.



За тази цел се използва двутактово изходно стъпало (push-pull). Неговата схема се състои от два комплементарни MOSFET транзистора – един N-канален (NMOS) за положителната полуwave на сигнала и един P-канален (PMOS) за отрицателната полуwave. Дрейновете на двата транзистора са свързани към съответните шини на захранването. Управляващият сигнал се подава към гейтовете, а сорсовете са свързани към изхода, често през предпазни резистори.

Ключови елементи в схемата са двете батерии към входния сигнал, които действат като DC offset. Те са необходими, тъй като MOSFET транзисторите имат прагово напрежение на отпушване (V_{GS}^{th}), което обикновено е в диапазона от 1.5 до 4 V. Ако входният сигнал не надвишава този праг, транзисторите остават запущени, което води до значителни преходни изкривявания (crossover distortion).



В зависимост от тези батерии, изходните стъпала се класифицират в различни режими на работа. В нашата схема е използван Клас АВ. При него DC offset-а на гейтовете е подбран така, че да бъде малко над прага на отпушване. Това осигурява малък "ток на покой", който държи транзисторите активни. Това елиминира "мъртвата зона", гарантирайки плавен преход на сигнала, като в един много тесен участък и двата транзистора провеждат ток едновременно.

4. Pre-Processing

Преди постъпването на данните в невронната мрежа е възможно към оригиналните EMG измервания да бъдат добавени допълнителни входни признаци, получени чрез предварителна обработка (pre-processing). Идеята е част от лесно извличимата информация от сигнала да бъде изчислена предварително, вместо невронната мрежа да трябва сама да открива тези зависимости от суровите данни. По този начин се увеличава информационното съдържание на входа, без да се премахва оригиналната информация.

Тези допълнителни входове могат да представляват прости математически характеристики на последните няколко измервателни фрейма. Например за всеки EMG канал може да се изчислява средната амплитуда на сигнала за избран времеви интервал. Тази стойност дава информация за общата сила на мускулната активност в разглеждания момент. Аналогично може да бъде използван и бинарен вход, получен чрез зададен праг (threshold): ако амплитудата или средната стойност на сигнала надхвърля определен праг, към мрежата се подава стойност 1, а в противен случай – 0. Подобни признаци са евтини за изчисляване и могат да предоставят на модела информация за наличието, продължителността или интензитета на определено мускулно активиране.

Към входа могат да бъдат добавени и други производни на първичните данни – например максимална и минимална стойност, средноквадратична стойност (RMS), промяна на сигнала между последователни фреймове или други характеристики, които могат да бъдат изчислени с малко количество изчислителни ресурси. При необходимост тези признаци могат да се изчисляват независимо за всеки сензор, което позволява на невронната мрежа да разполага както с локална информация от отделните канали, така и с обобщена информация за тяхното поведение.

Концепцията е подобна на използването на производни представяния на данните при други архитектури за машинно обучение. Вместо да се подава само

първоначалният сигнал, към него се добавят допълнителни представяния, съдържащи вече извлечена информация. По този начин първоначалните EMG данни запазват максимално много информация, а допълнителните входни неврони предоставят на модела предварително структурирани характеристики, които могат да бъдат полезни за класификацията.


В реализацията на „МиоБанд“ този подход позволява постепенно да се изследва кои производни на сигнала носят най-полезна информация за разпознаването на жестове. Тъй като изчисляването на тези признаци е значително по-просто от самото обучение на невронна мрежа, част от предварителната обработка може да бъде изпълнявана още преди подаването на данните към модела, включително върху самия микроконтролер. Това дава възможност да се търси баланс между размер на входния слой, изчислителна сложност и качество на класификацията.

5. Изкуствен интелект (Невронни мрежи)

Ролята на изкуствения интелект в проекта е да открива сложни нелинейни зависимости и патърни в постъпващите данни. В нашия случай, ИИ класифицира движенията и жестовите на ръката въз основа на филтрираните амплитудни импулси от мускулите (EMG данни). За целта използваме специализирана изкуствена невронна мрежа (Artificial Neural Network - ANN).

5.1. Структура на мрежата и Forward Propagation

Една невронна мрежа може да се представи като едно голямо нелинейно уравнение, изградено от слоеве: входен слой (приемащ стойностите от EMG сензорите), един или няколко скрити слоя (обработващи информацията) и изходен слой (даващ вероятностите за различните жестове).



Всеки неврон от даден слой е свързан с невроните от съседните слоеве. Всяка връзка притежава математическо тегло (weight - w), а всеки неврон има допълнително изместване (bias - b). Мрежата представлява масивна функция – при подаване на входни данни (напр. стойности на мускулно напрежение), те се умножават по теглата, събират се и преминават напред. Процесът на изчисляване на изхода на мрежата се нарича Forward Propagation.

Математически, за даден неврон j в следващия слой (z : pre-activation value):

$$z_j = \sum_i (x_i \cdot w_{ij}) + b_j$$

5.2. Activation Functions

За да се предотврати неконтролируемото нарастване на стойностите в невроните (което би довело до компютърно препълване и нестабилност) и за да се въведе нелинейна логика (без която мрежата би била просто една голяма линейна трансформация), се използват активиращи функции. За изходния слой на класификационната мрежа ще използваме функцията SoftMax, за да получим разпределение на вероятностите за всеки жест (сумата от изходите да е равна на 1 или 100%).

5.3. Backward Propagation

Функцията на загубите (Loss function) оценява доколко предсказанието на изкуствения интелект съвпада с реалния жест (етикета) по време на тренировъчния процес.

Производната на функцията на загубите спрямо теглата $\partial Loss / \partial w$ ни показва градиента – посоката и големината на грешката. На базата на тази производна се изчислява с колко трябва да се коригира всяко тегло в мрежата, започвайки отзад напред. Този алгоритъм се нарича Обратно разпространение на грешката (Backward Propagation).

Важно уточнение: По време на обратното разпространение, производната на активационната функция dActivation или $f'(z)$ е критичен компонент от верижното правило за диференциране (Chain Rule). Без нея е невъзможно грешката да премине правилно през скритите слоеве към началото на мрежата.

5.4. Gradient Descent и Learning Rate

Gradient Descent е оптимизационният алгоритъм, който актуализира теглата в мрежата. За да не се правят твърде резки корекции, които биха пропуснали глобалния минимум на грешката, градиентът се умножава по коефициент, наречен Learning Rate (LR):

$$w_{new} = w_{old} - LR \cdot \frac{\partial Loss}{\partial w}$$

Параметърът LR е строго положително число, обикновено много по-малко от 1 (напр. 0,01 или 0,001). Той определя темпото, с което невронната мрежа се адаптира към данните. По време на тренировъчния процес стойността на LR може динамично да се намалява или да се оптимизира чрез алгоритми като Adam, за да се ускори и стабилизира обучението на модела.

5.5. Loss function и SoftMax

В областта на машинното обучение съществуват различни функции за оценка на грешката (Loss functions), но за задачата за класификация на жестове въз основа на електромиографски сигнали е необходима метрика, която измерва разминаването между предсказаното от модела разпределение на вероятностите и действителното състояние. За тази цел се използва функцията Cross-Entropy Loss:

$$Loss = - \sum_{i=1}^K expected_i * \ln(predicted_i)$$

Тя изчислява грешката на базата на два компонента: очаквания отговор (верния отговор, предоставен от обучаващата извадка) и логаритъма от предсказаната от модела вероятност за този клас. Тъй като целевите данни в базата са кодирани така, че само верният жест има стойност 1, а всички останали са 0, сумата във функцията се опростява значително. На практика от всички възможни класове се взема предвид единствено логаритъмът от вероятността за верния отговор. Спецификата на логаритмичната функция гарантира, че ако моделът предскаже стойност, близка до нулата, за действителния жест, натрупаната грешка (загуба) нараства стръмно и клони към безкрайност. По този начин алгоритъмът бива строго "наказан" за грешни, но напълно уверени предсказания.

Функцията на кръстосаната ентропия обаче изисква входните данни да бъдат валидни вероятности (със стойности между 0 и 1). Суровите изходни стойности, генерирани от последния слой на невронната мрежа (наричани *логити*), не отговарят на това условие и могат да приемат всякакви стойности. Затова преди изчисляването на грешката към тях се прилага функцията SoftMax:

$$\sigma(z)_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

Тя трансформира изходите на мрежата чрез експоненциране и нормализация така, че сумата от вероятностите за всички възможни жестове винаги да е точно равна на 1 (100%). Това въвежда свойството на взаимна изключваемост между класовете – за да се увеличи увереността на модела за даден жест, вероятностите за останалите трябва пропорционално да намалеят.

Освен че осигурява нормализирано разпределение на вероятностите, използването на SoftMax в комбинация с функцията на кръстосаната ентропия има едно ключово математическо предимство по време на обратното разпространение на грешката (backward propagation). Производната на тази комбинирана функция се опростява до изключително прост израз – разликата между предсказаната вероятност и очакваната ($\partial L / \partial z = predicted_i - expected_i$). Тази директна линейна зависимост елиминира нуждата от сложни изчисления в последния слой, което значително намалява изчислителната тежест и оптимизира цялостния процес на обучение на модела.

5.6. Parallelization & CUDA optimization

Както бе описано в 7.1, изчисленията в една невронна мрежа са естествено подходящи за паралелизация. За всеки неврон изходът се получава чрез претеглена сума на стойностите от предходния слой – скаларно произведение (dot product) между вектора от стойности на предходния слой и съответния вектор от тежести, към което се добавя bias. При обучение същата структура се появява и при изчисляването на градиентите чрез backpropagation.

CPU е особено ефективен при последователни изчисления и при задачи с добра локалност (в RAM) на данните, но при невронните мрежи голяма част от операциите са независими една от друга и могат да се изпълняват едновременно. Именно това позволява чрез паралелизация множество по-малки изчислителни единици да постигнат по-висока обща производителност от един процесор, който изпълнява същите операции последователно.

В нашата реализация разглеждаме последователно четири нива на изпълнение: скаларна реализация, SIMD реализация върху CPU, SIMT реализация върху GPU и реализация, базирана на матрично умножение. Те не променят математиката на обучението, а променят начина, по който една и съща работа се разпределя между изчислителните ресурси. Това позволява директно сравнение на ефекта от различните форми на паралелизъм.

При скаларната реализация едно изчисление се изпълнява след друго. При изчисляването на един dot product всяко умножение и последващото събиране се извършват последователно. Това е най-простият вариант и служи като естествена база за сравнение с останалите реализации.

Първата оптимизация на CPU е SIMD (Single Instruction, Multiple Data). При нея една инструкция обработва няколко стойности едновременно. Например 128-битов SIMD регистър може да съдържа четири стойности от тип float32 и съответната SIMD инструкция може да извърши една и съща операция върху четирите елемента паралелно. По-нови процесори поддържат и по-широки регистри, например 256 или 512 бита. Реалното ускорение зависи от конкретния процесор.

При разработката на SIMD реализацията сравнихме резултатите с базовата скаларна реализация и потвърдихме, че двете дават еквивалентни резултати. Основното ограничение на този подход е мащабирането: броят на елементите, обработвани с една инструкция, е ограничен от ширината на SIMD регистрите и от възможностите на конкретния CPU. За да се използва паралелизъм върху значително по-голям брой независими операции, е подходящ GPU.

GPU е проектиран да поддържа голям брой паралелни „нишки“ (threads – поредица от операции; CPU-то е пример за single-thread програмиране). При NVIDIA GPU нишките се изпълняват на „streaming мултипроцесори“ (SM), като нишките са групирани в warp-ове от по 32 нишки. В CUDA моделът за програмиране се нарича SIMT (Single Instruction, Multiple Threads): нишките от един warp изпълняват една и съща инструкция върху различни данни. Поради наличието ни на NVIDIA GPU-та, използвахме CUDA за GPU програмирането.

В SIMT реализацията ни паралелизираме изчисленията по sample-ите и по невроните. Двумерната конфигурация на grid-а използва едната координата (y) за sample-ите, а другата (x) – за невроните. Вътре в съответните блокове нишките обработват елементи от batch-а. Размерът на warp-а винаги е 32 нишки. За това (сравнително арбитрарната ни) константа SAMPLES=512 е кратна на 32 – за да не се прехосват нишки в warp-а. Ако някоя нишка не е необходима, тя не върши работа. Това е причината за размери на batch (за mini-batching) и на слоевете, кратни на 32, често да са оптимални за GPU изпълнението, но кратност 32 не е изискване.

5.7. Матрично умножение

Третото ниво на оптимизация е да се разглежда обучението като последователност от матрични операции. Вместо да се мисли за всеки неврон поотделно, стойностите на всички sample-и от един batch могат математически да се представят като матрица. В тази форма forward propagation, backward propagation и gradient descent могат да бъдат изразени чрез матрични умножения.

Важно е да се направи разлика между математическата форма на тези матрици и начина, по който данните физически са разположени в паметта. В програмата стойностите и градиентите се адресират чрез индекс от вида ``node * batch_size + sample``, т.е. sample-ите са вътрешното измерение в използвания масив. Следователно описаните по-долу матрици са концептуалната математическа форма на операцията, докато конкретните транспозиции в cuBLAS адаптират тази форма към реалното представяне в паметта.

а. При forward propagation стойностите от текущия слой се умножават по матрицата от тежести към следващия слой. В математическа форма, ако X е матрицата от sample-и, а W е матрицата от тежести, операцията може да се запише като $X \cdot W$. Общото измерение – броят неврони в текущия слой – се сумира и отпада, а резултатът съдържа стойностите на невроните от следващия слой за всички sample-и.

б. При backward propagation $dLoss/dX$ се разпространява от следващия слой към текущия. В математическа форма това съответства на умножение на матрицата с градиентите на следващия слой по транспонираната матрица на тежестите, т.е. $\Delta_l = \Delta_{l+1} \cdot W^T$. Така отново се сумира общото измерение – броят неврони в следващия слой – и се получават градиентите за невроните от текущия слой. Реалната cuBLAS операция използва подходяща комбинация от транспониране и нетранспониране според вътрешното представяне на данните.

в. При изчисляването на градиентите на тежестите трябва да се комбинират стойностите на текущия слой с градиентите на следващия слой за всички sample-и. Това може да се представи като $X^T \cdot \Delta$. Така измерението на batch-а се редуцира и резултатът има размерите на матрицата от тежести – брой неврони в текущия слой $\times$ брой неврони в следващия слой. След това получените градиенти се използват от оптимизатора за актуализиране на параметрите.

Предимството на матричната формулировка не е само в по-компактното описание на алгоритъма. Операцията GEMM (General Matrix-Matrix Multiplication) е една от най-добре оптимизирани числени операции в съвременните изчислителни библиотеки. В нашата реализация използваме cuBLAS и конкретно `cublasSgemm`, вместо да имплементираме собствен kernel за общо матрично умножение. Библиотеката може да използва хардуерните възможности на GPU и различните нива на паметта – регистри, кешове и глобална GPU памет – така че данните да се използват максимално ефективно.

Това прави `matmul` подхода значително по-трудоемък за имплементиране от обикновените паралелни `kernel`-и, ако трябва да се разработва от нулата. Използването на cuBLAS обаче позволява да се възползваме от вече реализирани и силно оптимизирани GEMM операции. В конкретната имплементация `forward propagation`, `backward propagation` и изчисляването на градиентите на тежестите преминават през обща функция ``matmul``, която избира съответната cuBLAS операция според контекста. Финалното сравнение между методите показва подобрението ([MyoBand/MachineLearning/nd1/ comparison.txt](#)):



Конкретният тест представлява проста задача за откриване дали случайна точка в единичния куб пада в единичната сфера. Тренира се на 10000 sample-a; мрежа с дълбочина 5 слоя (3 скрити) и ширина 64 неврона; за 10000 епохи. Техниката е: Intel Core i7-9700KF CPU @ 3.60GHz; NVIDIA GeForce RTX 2060 SUPER – 8GB VRAM.

Получените времена показват ясно ефекта от последователното прилагане на тези оптимизации: скаларната реализация отнема 2673 s, SIMD реализацията – 294 s, SIMT реализацията – 107 s, а `matmul` реализацията – 12 s. Така SIMD намалява времето приблизително деветократно спрямо скаларния вариант, SIMT дава допълнително ускорение, а използването на оптимизирани GEMM операции в cuBLAS води до най-голямото ускорение.

6. Post-Processing: Интерпретиране на резултатите.

След като невронната мрежа обработи входните данни и определи вероятността за всеки от предварително зададените жестове, получените резултат се подлага на последваща обработка (post-processing). За основна команда се избира тази, за която моделът е дал най-висока вероятност. След това избраният жест се преобразува в конкретна команда, която се изпълнява на свързания компютър чрез съответния програмен скрипт.

Този подход разделя разпознаването на жеста от действителното му приложение. Невронната мрежа има задача да определи какво движение е извършено, докато post-processing етапът определя как това движение да бъде интерпретирано от операционната система. По този начин една и съща система за разпознаване може да бъде използвана в различни приложения, като значението на отделните жестове може да бъде променяно според нуждите на потребителя или конкретната програма.

В разработваната система са предвидени няколко предварително програмирани примерни команди, които могат да бъдат задействани чрез разпознатите жестове:

- a. LMB (Left Mouse Button)
- b. RMB (Right Mouse Button)
- c. Close Window (Alt + F4)
- d. Back (Alt + Left Arrow)
- e. Forward (Alt + Right Arrow)
- f. No gesture

Командите се изпълняват от компютърната част на системата чрез предварително зададени скриптове, които преобразуват резултата от класификацията в стандартно действие на операционната система. Това позволява разпознатите жестове да се използват като алтернативен входен интерфейс и да заменят физическото взаимодействие с клавиатура или мишка в подходящи сценарии.

Съществено предимство на този подход е възможността за лесно пренастройване на поведението на системата. Самата невронна мрежа не е необходимо да бъде променяна при всяка промяна на предназначението на даден жест – достатъчно е съответният резултат от класификацията да бъде свързан с друга команда или скрипт. По този начин „МيوБанд“ може да бъде адаптиран към различни приложения и работни среди, без да се променя основният принцип на разпознаване.

7. Апликации

Разработената система „МيوБанд“ има потенциал за приложение в различни области, в които е необходимо безконтактно или алтернативно управление чрез движения и мускулна активност. В медицински контекст технологията може да бъде използвана за изследване и проследяване на

мускулна активност, както и като основа за помощни интерфейси за хора с двигателни затруднения. В индустрията разпознаването на жестове може да се използва за дистанционно управление на електронни и механични системи, особено в ситуации, при които физическият достъп до машината е неудобен или потенциално опасен.

Други възможни приложения включват управление на виртуална и аугментирана реалност, интерактивни системи и роботика, както и реализация на естествени интерфейси човек–компютър, например чрез въздушно писане или управление на курсора. Съществено предимство е, че разпознаването на жеста и неговото последващо интерпретиране са отделени на различни етапи, което позволява една и съща хардуерна и AI система да бъде адаптирана към различни приложения чрез промяна на съответните команди и скриптове.

8. Заключение

В рамките на проекта „МиоБанд“ беше разработена концепция и функциониращ прототип на носима система за разпознаване на жестове на ръката чрез повърхностна електромиография (sEMG). Основната цел на разработката беше да се изследва възможността за използване на мускулната електрическа активност като алтернативен интерфейс за управление на компютър чрез безжична комуникация. За постигането на тази цел бяха разгледани и реализирани взаимосвързани хардуерни, софтуерни и алгоритмични компоненти.

Хардуерната част включва специално проектирана печатна платка, EMG сензори и усилвателни схеми, микроконтролер ESP32-S3, както и MPU-6050 за измерване на ускорение и ъглова скорост. Компонентите са интегрирани в компактна носима конструкция, захранвана от Li-Po батерия. По този начин е реализирана цялостна измервателна система, която може да регистрира мускулната активност и едновременно с това да използва информация за движението на гъривната.

В софтуерната част са разработени етапи за обработка и интерпретиране на получените сигнали и е реализирана невронна мрежа за класификация на предварително зададени жестове. Използването на предварителна обработка позволява към суровите EMG данни да бъдат добавяни допълнителни признаци, като средна амплитуда, прагова информация, максимална и минимална стойност, RMS и промени между последователни измервателни фреймове. Този подход дава възможност част от лесно извличимата информация да бъде представена предварително, вместо цялата зависимост да бъде научавана от невронната мрежа директно от суровия сигнал. Така може да се търси баланс между размер на входа, изчислителна сложност и качество на класификацията.

Особено важен аспект от разработката е разделянето на разпознаването от прилагането на резултата. Невронната мрежа определя кой жест е извършен, а post-processing етапът преобразува избрания клас в конкретна команда към операционната система. Това прави архитектурата по-гъвкава, тъй като предназначението на даден жест може да бъде променяно без необходимост от повторно разработване на самия модел.

8.1. Приноси

Оригиналният принос на проекта се състои не само в крайното интегриране на отделните компоненти, но и в самостоятелното разработване и изследване на различни части от системата. В хардуерно отношение е търсена компактна и специализирана реализация, съобразена с конкретните нужди на проекта, вместо директно използване на готови универсални модули. При оптимизацията на схемата е обръщано внимание и на това кои елементи са реално необходими при използваните работни напрежения и режими. Например са разглеждани възможности за намаляване на хардуерната сложност чрез премахване или ограничаване на защити и компоненти, които не допринасят съществено за работата на системата при конкретните ѝ условия на експлоатация. По този начин оптимизацията е насочена не само към функционалност, но и към размер, простота и ефективност на крайното устройство.

При обработката на данните оригинален елемент е и изследването на различни представяния на информацията преди подаването ѝ към AI модела. Изборът на подходящи pre-processing характеристики може да намали необходимото количество работа, която невронната мрежа трябва да извършва сама, като същевременно се запазва основната информация от EMG сигнала. Съответно post-processing слойът позволява отделянето на математическата задача за класификация от конкретното приложение на разпознатия жест. Това улеснява адаптирането на системата към различни сценарии на използване.

Друг съществен принос е разработването и сравнението на различни реализации на алгоритмите за обучение на невронната мрежа – от последователна скаларна реализация през SIMD върху CPU и SIMT върху GPU до матрична реализация с cuBLAS. За конкретния разглеждан тест времето за изпълнение е намалено от 2673 s при скаларната реализация до 294 s при SIMD, 107 s при SIMT и 12 s при реализацията чрез оптимизирани GEMM операции. Тези резултати показват значителния ефект от използването на паралелизъм и подходящи библиотеки за числени изчисления, като същевременно демонстрират, че една и съща математическа задача може да бъде реализирана по различни начини в зависимост от наличните изчислителни ресурси.

В резултат на извършената работа е показана принципната възможност за изграждане на компактна носима система, която превръща информацията от мускулната активност в цифрови команди. По този начин поставената основна цел – проектиране, изграждане и изследване на функциониращ прототип на гривна за разпознаване на жестове – е изпълнена, а отделните задачи, свързани с хардуера, обработката на данните и изкуствения интелект, са обединени в единна система.

8.2. Бъдещо развитие

Следваща стъпка в развитието на „МиоБанд“ е по-пълното интегриране на данните от акселерометъра и жирокопа в процеса на разпознаване. В настоящата архитектура тези данни са предвидени за допълнително разграничаване на жестове или за реализиране на директни функции, но тяхното по-задълбочено използване може да даде допълнителна информация, недостъпна само чрез EMG сигналите.

Една от естествените посоки е използването на жирокопа и акселерометъра за директно управление на позицията на курсора на мишката. В този случай EMG каналите могат да се използват за разпознаване на команди като натискане на ляв или десен бутон, докато ориентацията и движението на гривната определят посоката на движение на курсора.

Друга важна посока е използването на ориентацията на гривната още на етапа на pre-processing. При промяна на положението на ръката един и същ жест може да породи различни комбинации от измервания от сензорите. Вместо невронната мрежа да трябва да научава всички възможни пространствени ориентации като отделни варианти, данните от акселерометъра и жирокопа могат да бъдат използвани за оценяване на текущата ориентация и последващо нормализиране или преориентиране на EMG информацията. По този начин част от вариативността може да бъде отстранена още преди подаването на сигнала към AI модела. Това би могло да намали зависимостта от големи тренировъчни набори и да подобри способността на системата да се обобщава към различни положения на гривната.

В бъдещи версии може да бъде изследвана и по-сложна комбинация между EMG, акселерометрични и жирокопични признаци, както и автоматичен избор на най-информативните характеристики. Това би позволило да се установи кои комбинации от сурови и предварително обработени данни дават най-добър баланс между точност, устойчивост и изчислителна цена. Същевременно изчисленията, които не изискват значителен ресурс, могат да бъдат прехвърлени към микроконтролера, така че по-голяма част от обработката да се извършва локално.

В по-дългосрочен план системата може да бъде разширена с повече жестове, персонализирано обучение за различни потребители и по-гъвкаво свързване между разпознатите класове и действията, които те предизвикват. Това би позволило „МиоБанд“ да се превърне от прототип в инструмент за алтернативно взаимодействие между човек и компютър, при който хардуерът и алгоритмите могат да бъдат адаптирани към конкретното приложение, без да се променя основният принцип на работа.

9. Източници

9.1. Основни:

Fiore, James M. 2018. *Operational Amplifiers & Linear Integrated Circuits: Theory and Application*. 3rd ed. Utica, NY: Mohawk Valley Community College:
www2.mvcc.edu/users/faculty/jfiore/books/OperationalAmplifiersAndLinearICs_3E.pdf
NVIDIA, *CUDA C++ Programming Guide*, release 13.3 (May 2026):
docs.nvidia.com/cuda/cuda-programming-guide/pdf/cuda-programming-guide.pdf

9.2. Странични:

Seeed Studio: *Grove EMG Detector*:

wiki.seeedstudio.com/Grove-EMG_Detector/

Mitchell Hashimoto's blog: *Everyone Should Know SIMD*:

mitchellh.com/writing/everyone-should-know-simd

YouTube, Andrej Carpathy: *Neural Networks: Zero to Hero*:

www.youtube.com/playlist?list=PLAqhlrjkbWl23v9cThsA9GvCAUhRvKZ

YouTube, Electronics with Professor Fiore: *The Current Mirror*:

www.youtube.com/watch?v=w7SdmP21S7w

YouTube, All Electronics Channel: *Push-Pull Pair - Class B, Class AB and Class A operation*:

www.youtube.com/watch?v=S7jrfsfkNw

YouTube, Vocademy - Electronics Technology: *Small Signal Amplifiers*:

www.youtube.com/watch?v=WgOKPF8LkA8

МиоБанд

Автори: Никола Д. Лиров, Виктор М. Атанасов, Станислав К. Янков, Ян Р. Генов

GitHub: github.com/MyoBand-Group/MyoBand

Дата: 04 октомври, 2026 г.